

1 1. Klasyczna Regresja Liniowa (OLS)

Regresja liniowa to metoda statystyczna, która pozwala zbadać zależność między różnymi zjawiskami i przewidzieć wartość jednego z nich na podstawie innych.

Jej celem jest znalezienie takiej prostej (linii), która najlepiej "przechodzi" przez punkty na wykresie. W klasycznej metodzie najmniejszych kwadratów (ang. *Ordinary Least Squares*) dążymy do zminimalizowania sumy kwadratów różnic między wartościami rzeczywistymi (y_i), a przewidzianymi ($\hat{y}_i$).

Funkcja celu (Strata):

$$L_{OLS}(\beta) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n \left(y_i - \sum_{j=1}^p x_{ij} \beta_j \right)^2 \quad (1)$$

Gdzie:

- n – liczba obserwacji,
- p – liczba cech (zmiennych),
- β_j – współczynniki regresji, które chcemy wyznaczyć.

Problem: Jeśli cech (p) jest dużo, a danych mało, model staje się zbyt elastyczny i dopasowuje się do szumu (*overfitting*).

2 2. Regresja Lasso (L1 Regularization)

Lasso (*Least Absolute Shrinkage and Selection Operator*) modyfikuje funkcję celu, dodając do niej tzw. karę za wielkość współczynników.

Funkcja celu Lasso:

$$L_{Lasso}(\beta) = \underbrace{\sum_{i=1}^n \left(y_i - \sum_{j=1}^p x_{ij} \beta_j \right)^2}_{\text{Błąd dopasowania (OLS)}} + \lambda \underbrace{\sum_{j=1}^p |\beta_j|}_{\text{Kara L1}} \quad (2)$$

Gdzie:

- λ – parametr regularyzacji ($\lambda \geq 0$),
- $\sum |\beta_j|$ – suma wartości bezwzględnych współczynników (norma L_1).

Jak to działa?

- **Kurczenie (Shrinkage):** Kara zmusza model, aby wartości β były jak najmniejsze.
- **Selekcja cech:** Lasso posiada unikalną właściwość – dla odpowiednio dużego λ redukuje niektóre współczynniki dokładnie do zera.
- **Efekt:** Otrzymujemy model rzadszy (*sparse model*), który korzysta tylko z najważniejszych zmiennych.

3 3. Kluczowe różnice w interpretacji

Cecha	Regresja OLS	Regresja Lasso
Liczba zmiennych	Wykorzystuje wszystkie dostępne zmienne.	Wybiera tylko te najistotniejsze.
Współczynniki	Mogą przyjmować dowolnie duże wartości.	Są "ściskane" w stronę zera.
Złożoność	Wysoka (ryzyko <i>overfittingu</i>).	Niska (lepszą generalizacją).
Parametry	Brak parametrów dodatkowych.	Wymaga doboru optymalnego λ .

4 4. Dlaczego standaryzacja jest konieczna?

Spójrzmy na człon kary: $\lambda \sum |\beta_j|$. Wartość β_j bezpośrednio zależy od skali zmiennej x_j . Bez standaryzacji, zmienne o bardzo małych wartościach liczbowych miałyby nienaturalnie duże współczynniki β , przez co kara λ uderzałaby w nie znacznie mocniej.

Standaryzacja sprowadza wszystkie zmienne do wspólnej skali:

$$x'_{ij} = \frac{x_{ij} - \bar{x}_j}{\sigma_j} \quad (3)$$

Dzięki temu każda cecha ma średnią 0 i odchylenie standardowe 1, a kara λ jest nakładana sprawiedliwie na wszystkie współczynniki.